



Instituto Brasileiro de Ensino, Desenvolvimento e Pesquisa – IDP
Curso de Mestrado Profissional em Administração Pública

Pipeline para geração e avaliação de dados sintéticos com utilidade analítica em risco cibernético

Mauricio da Silva Marinho
Orientador: Prof. Jean Nunes Araujo

Brasília-DF
2027

MAURICIO DA SILVA MARINHO

Pipeline para geração e avaliação de dados sintéticos com utilidade analítica em risco cibernético

Dissertação apresentada ao programa de pós-graduação em Administração Pública, como parte do requisito para a obtenção do título de Mestre em Administração Pública pelo Instituto Brasileiro de Ensino, Desenvolvimento e Pesquisa – IDP.

Orientador(a): Prof. Jean Nunes Araujo

Brasília-DF
2027

MARINHO, Mauricio da Silva

Pipeline para geração e avaliação de dados sintéticos com utilidade analítica em risco cibernético / Mauricio da Silva Marinho. – Brasília: IDP, 2027.

00 p.

Inclui bibliografia.

Trabalho de Conclusão de Curso (Dissertação) – Instituto Brasileiro de Ensino, Desenvolvimento e Pesquisa – IDP, Curso de Mestrado Profissional em Administração Pública, Brasília, 2027.

Orientador: Prof. Jean Nunes Araujo.

1. Dados sintéticos. 2. Risco cibernético. 3. Governança de dados. I. Título.

CDD: XXX

Ficha catalográfica elaborada pela Biblioteca Ministro Moreira Alves
Instituto Brasileiro de Ensino, Desenvolvimento e Pesquisa – IDP

MAURICIO DA SILVA MARINHO

Pipeline para geração e avaliação de dados sintéticos com utilidade analítica em risco cibernético

Dissertação apresentada ao programa de pós-graduação em Administração Pública, como parte do requisito para a obtenção do título de Mestre em Administração Pública pelo Instituto Brasileiro de Ensino, Desenvolvimento e Pesquisa – IDP.

Orientador(a): Prof. Jean Nunes Araujo

Brasília, junho de 2027.

Banca Examinadora

Prof. Jean Nunes Araujo
Orientador

A definir
Examinador

A definir
Examinador

*Dedico aos meus pais, por todo amor, confiança
e apoio em toda a minha vida.
Dedico também a todos que estiveram comigo
durante a realização do meu curso.*

AGRADECIMENTOS

Agradeço à minha família, pelo apoio incondicional em todos os momentos desta caminhada.

Ao meu orientador, Prof. Jean Nunes Araujo, pela paciência, pela generosidade intelectual e pelo rigor com que conduziu a orientação deste trabalho.

Aos professores e servidores do Instituto Brasileiro de Ensino, Desenvolvimento e Pesquisa – IDP, pela formação recebida.

Aos colegas de turma, pelas discussões que ajudaram a amadurecer as ideias aqui apresentadas.

“A ciência é feita de dados como uma casa é feita de pedras. Mas um amontoado de dados não é ciência, assim como um monte de pedras não é uma casa.”

(POINCARÉ, 1902, p. 141)

RESUMO

A pesquisa trata da necessidade de produzir dados sintéticos de risco cibernético que sejam suficientemente fiéis e úteis para análise, sem pressupor que a geração sintética, por si só, assegure privacidade ou validade analítica. O pipeline metodológico será organizado em seis etapas: análise exploratória e preparação dos dados; geração sintética com CTGAN e, quando viável, um baseline não neural; avaliação de fidelidade; avaliação de utilidade analítica; avaliação de risco de exposição; e síntese dos resultados e definição das condições de uso. A utilidade será avaliada pelo protocolo TSTR, comparado a TRTR, em uma tarefa analítica definida a priori. O artefato será considerado tecnicamente promissor se apresentar, simultaneamente, evidências de fidelidade, utilidade analítica adequada ao workload definido e ausência de sinais relevantes de exposição.

Palavras-chave: Dados sintéticos. CTGAN. Risco cibernético. Utilidade analítica. Governança de dados.

ABSTRACT

This research addresses the need to produce synthetic cyber risk data that are sufficiently faithful and useful for analysis, without assuming that synthetic generation, by itself, ensures privacy or analytical validity. The methodological pipeline will be organized in six stages: exploratory analysis and data preparation; synthetic generation with CTGAN and, when feasible, a non-neural baseline; fidelity evaluation; analytical utility evaluation; exposure risk evaluation; and synthesis of the results and definition of the conditions of use. Utility will be evaluated through the TSTR protocol, compared with TRTR, on an analytical task defined a priori. The artifact will be considered technically promising if it simultaneously presents evidence of fidelity, analytical utility adequate to the defined workload, and absence of relevant signs of exposure.

Keywords: Synthetic data. CTGAN. Cyber risk. Analytical utility. Data governance.

LISTA DE ILUSTRAÇÕES

Figura 1 – Fluxo de preparação dos dados (data airlock)	18
---	----

LISTA DE TABELAS

Tabela 1 – Etapas de avaliação, técnicas de análise e hipóteses	18
---	----

LISTA DE QUADROS

LISTA DE GRÁFICOS

LISTA DE ABREVIATURAS E SIGLAS

ABNT	Associação Brasileira de Normas Técnicas
CDD	Classificação Decimal de Dewey
DPP	Decanato de Pesquisa e Pós-Graduação
IDP	Instituto Brasileiro de Ensino, Desenvolvimento e Pesquisa
MEC	Ministério da Educação
RDs	Repositórios Digitais
TCC	Trabalho de Conclusão de Curso

SUMÁRIO

1	INTRODUÇÃO.....	15
2	REFERENCIAL TEÓRICO.....	16
2.1	Dados sintéticos e o desafio dos dados tabulares	16
2.2	Avaliação da utilidade de dados sintéticos	16
3	PROCEDIMENTOS METODOLÓGICOS	18
4	ANÁLISE E DISCUSSÃO DOS DADOS.....	19
5	CONSIDERAÇÕES FINAIS.....	20
	REFERÊNCIAS	21
	APÊNDICE A – Roteiro de entrevista semiestruturada	22
	APÊNDICE B – Tabelas complementares	23
	ANEXO A – Legislação de referência	24

1 INTRODUÇÃO

A transformação digital da Administração Pública e a crescente dependência de infraestruturas tecnológicas ampliaram a importância da gestão de riscos cibernéticos para a continuidade de serviços, a proteção de informações e a capacidade institucional de cumprir sua missão. Ao mesmo tempo, a expansão de ambientes digitais aumenta a quantidade e a complexidade dos dados produzidos por processos de segurança da informação, entre eles registros de ativos, vulnerabilidades, exposições, criticidade e indicadores de ameaças. Esses dados possuem elevado potencial para apoiar pesquisa, experimentação, auditoria, desenvolvimento de modelos analíticos e avaliação de políticas e controles, mas também podem revelar características sensíveis da infraestrutura e da capacidade defensiva de uma organização.

Essa tensão produz um problema relevante para a Ciência de Dados aplicada ao setor público: modelos analíticos dependem de dados suficientemente ricos para capturar relações entre variáveis, enquanto a organização possui razões legítimas para restringir a exposição dos dados originais. A geração de dados sintéticos surge, nesse contexto, como uma alternativa para ampliar o acesso controlado a dados de pesquisa e experimentação, sem pressupor que a simples substituição de registros reais por registros artificiais seja suficiente para preservar o valor analítico.

Assim, estabelece-se como problema de pesquisa a necessidade de produzir dados sintéticos de risco cibernético que sejam suficientemente fiéis e úteis para análise, sem pressupor que a geração sintética, por si só, assegure privacidade ou validade analítica.

2 REFERENCIAL TEÓRICO

O referencial teórico será organizado em torno de uma questão central: a geração de dados sintéticos não deve ser avaliada apenas pela capacidade de produzir registros plausíveis, mas pela relação entre fidelidade, utilidade analítica e risco de exposição. Essa perspectiva permite deslocar o foco de uma avaliação centrada exclusivamente no algoritmo gerador para uma avaliação orientada ao uso do artefato, coerente com o caráter aplicado da pesquisa.

2.1 Dados sintéticos e o desafio dos dados tabulares

Para dados tabulares heterogêneos, a escolha do modelo torna-se particularmente importante. Xu et al. (2019) destacam que tabelas combinam variáveis discretas e contínuas, distribuições multimodais e categorias desbalanceadas, características que dificultam a aplicação direta de modelos tradicionais. A CTGAN foi proposta como uma arquitetura condicional para enfrentar parte desses problemas, utilizando condicionamento e estratégias específicas para variáveis categóricas.

Uma das contribuições mais importantes para a avaliação de dados sintéticos é a distinção entre utilidade geral e utilidade específica proposta por Snoke et al. (2018). A utilidade geral procura avaliar se os dados sintéticos possuem distribuição comparável à dos dados originais; a utilidade específica, por sua vez, compara os resultados de uma análise concreta realizada nos dois datasets. Essa distinção é fundamental porque um dataset pode reproduzir distribuições marginais de forma satisfatória e, ainda assim, falhar em preservar relações importantes para uma tarefa analítica.

2.2 Avaliação da utilidade de dados sintéticos

A necessidade de relacionar a métrica à finalidade da avaliação aparece no estudo de validação de métricas de utilidade conduzido por El Emam e colaboradores:

A regular task by developers and users of synthetic data generation (SDG) methods is to evaluate and compare the utility of these methods. Multiple utility metrics have been proposed and used to evaluate synthetic data. However, they have not been validated in general or for comparing SDG methods. (EL EMAM et al., 2022)

No estudo, foram avaliadas seis métricas em 30 datasets e três métodos de geração, e a distância multivariada de Hellinger baseada em uma representação Gaussian Copula apresentou


o melhor desempenho para o objetivo de ranquear os métodos (EL EMAM et al., 2022). O resultado reforça uma questão central desta pesquisa: a métrica escolhida deve ser relacionada à finalidade da avaliação, e não apenas à facilidade de cálculo.

3 PROCEDIMENTOS METODOLÓGICOS

A estratégia metodológica incorpora princípios de Design Science Research, especialmente a construção e avaliação de um artefato orientado a um problema relevante. O artefato principal será o pipeline de geração e avaliação de dados sintéticos, e não o modelo CTGAN isoladamente. Essa distinção é importante porque o objeto de avaliação é o processo completo — preparação, geração, validação e uso analítico — e não apenas o algoritmo.

A preparação seguirá um fluxo de data airlock, representado na Figura 1: (1) extração controlada; (2) identificação de atributos sensíveis; (3) remoção ou transformação de identificadores; (4) generalização ou agrupamento de categorias raras quando necessário; (5) criação do dataset de treinamento; e (6) manutenção de um conjunto real de teste isolado. O conjunto de teste real permanecerá inacessível ao treinamento do gerador e será utilizado exclusivamente para avaliação final de utilidade.

Figura 1 – Fluxo de preparação dos dados (data airlock)



Fonte: Elaborado pelo autor (2026).

O pipeline metodológico será organizado em seis etapas: análise exploratória e preparação dos dados; geração sintética com CTGAN e, quando viável, um baseline não neural; avaliação de fidelidade; avaliação de utilidade analítica; avaliação de risco de exposição; e síntese dos resultados e definição das condições de uso. A Tabela 1 relaciona as etapas de avaliação às técnicas de análise e às hipóteses do estudo.

Tabela 1 – Etapas de avaliação, técnicas de análise e hipóteses

Etapas	Técnicas de análise	Hipótese
Fidelidade	Distribuições, KS, associações e clustering	H1
Utilidade	TRTR $\times$ TSTR; PR-AUC, recall e F1	H2
Exposição	Proximidade, memorização e membership	H3

Fonte: Elaborado pelo autor (2026).

4 ANÁLISE E DISCUSSÃO DOS DADOS

O protocolo TRTR será utilizado como referência: modelo treinado em dados reais de treinamento e testado em dados reais de teste. O protocolo TSTR será o experimento principal: modelo treinado em dados sintéticos e testado no mesmo conjunto real de teste. Para classes desbalanceadas serão priorizados PR-AUC, recall, F1 e, quando pertinente, intervalos de confiança; ROC-AUC será complementar e não será utilizado isoladamente.

O artefato será considerado tecnicamente promissor se apresentar, simultaneamente, evidências de fidelidade nas métricas selecionadas, utilidade analítica adequada ao workload definido e ausência de sinais relevantes de exposição segundo os critérios estabelecidos. Nenhuma dimensão será considerada suficiente isoladamente. Um dataset que seja estatisticamente semelhante, mas não preserve a tarefa analítica, não será classificado como útil; da mesma forma, um dataset útil, mas com risco elevado de reprodução de registros, não será considerado adequado para compartilhamento.

5 CONSIDERAÇÕES FINAIS

No domínio de privacidade, os testes propostos serão entendidos como avaliação empírica de risco de exposição, e não como demonstração de privacidade absoluta. A pesquisa buscará identificar sinais de proximidade excessiva, memorização ou membership disclosure segundo os procedimentos definidos. Garantias formais, como as proporcionadas por mecanismos de privacidade diferencial, permanecem como possibilidade de investigação futura. Essa delimitação impede que a ausência de evidência de exposição nos testes seja interpretada como prova de risco zero.

Outra limitação refere-se à validade externa. A pesquisa será conduzida a partir de um contexto organizacional específico e de dados associados à gestão de vulnerabilidades. Ainda que o pipeline seja documentado de forma a permitir reaplicação, os resultados poderão refletir características particulares do ambiente estudado, de sua arquitetura tecnológica, de seus processos e de seu nível de maturidade. Dessa forma, as conclusões serão apresentadas como evidência de um caso aplicado, e não como demonstração de validade universal para organizações públicas ou reguladas.

REFERÊNCIAS

EL EMAM, Khaled; MOSQUERA, Lucy; FANG, Xi; EL-HUSSUNA, Alaa. Utility metrics for evaluating synthetic health data generation methods: validation study. **JMIR Medical Informatics**, v. 10, n. 4, e35734, 2022. DOI: 10.2196/35734.

SNOKE, Joshua; RAAB, Gillian M.; NOWOK, Beata; DIBBEN, Chris; SLAVKOVIC, Aleksandra. General and specific utility measures for synthetic data. **Journal of the Royal Statistical Society: Series A (Statistics in Society)**, v. 181, n. 3, p. 663–688, 2018. DOI: 10.1111/rssa.12358.

XU, Lei; SKOULARIDOU, Maria; CUESTA-INFANTE, Alfredo; VEERAMACHANENI, Kalyan. Modeling tabular data using conditional GAN. In: **ADVANCES in Neural Information Processing Systems**. [S.l.: s.n.], 2019. v. 32, p. 7338–7347.

APÊNDICE A – ROTEIRO DE ENTREVISTA SEMIESTRUTURADA

Insira aqui o conteúdo do apêndice: questionários, roteiros, formulários de consentimento, transcrições ou qualquer outro material produzido por você.

APÊNDICE B – TABELAS COMPLEMENTARES

Insira aqui o conteúdo do segundo apêndice. Cada chamada de `\apendice{}` gera automaticamente uma nova página e uma entrada no sumário.

ANEXO A – LEGISLAÇÃO DE REFERÊNCIA

Insira aqui o conteúdo do anexo: cópias de leis, pareceres, laudos, mapas ou qualquer material de terceiros que sustente a argumentação do trabalho.